

Partie INFRA

Documentation Hackathon IA

Déploiement serveur inférence Phi3.5-Financial

DANTE Julien - DERIU Vito – FAGNIART Kantin – HERRY
Arthur – Pivot Nathanael
30/06/2026

Table des matières

1.	Materiel physique	1
2.	Installation du serveur d'inférence Ollama	1
3.	Choix du model	1
4.	Accessibilité du serveur	2
5.	Application Frontend	2
6.	Nom de domaine et Accès Cloudflare	3
7.	Application rendu sur internet	4

1. Materiel physique

Notre projet a été réalisé sur un serveur Dell PowerEdge R730xd ne possédant pas de processeur graphique, nos choix ont donc été limité à l'usage du CPU seulement. Nous avons utilisé une machine virtuelle sur l'hyperviseur Proxmox.

Spécificité technique de la machine virtuelle :

Debian 13 (trixie) - 16vCPU – 64Gb RAM – 250Go Stockage – Pas de GPU

2. Installation du serveur d'inférence Ollama

Limités physiquement nous avons choisi le serveur d'inférence Ollama qui permet de faire tourner des modèles grâce au CPU. L'installation du serveur s'est effectuée sans encombre en suivant la documentation officielle d'Ollama pour linux :

```
curl -fsSL https://ollama.com/install.sh | sh
```

<https://docs.ollama.com/quickstart>

3. Choix du model

Voici les paramètres d'inférences utilisés dans le Modelfile mis à notre disposition :

- **temperature 0.3** : réponses précises et factuelles, peu de créativité. Notre model est un model financier donc il ne doit pas être créatif.
- **top_p 0.9** : limite les tokens improbables et réduit les hallucinations.
- **top_k 40** : restreint le choix aux 40 tokens les plus probables à chaque étape.
- **num_predict 1024** : permet des réponses suffisamment longues pour des analyses financières.
- **repeat_penalty 1.1** : évite les répétitions dans les réponses.

```
FROM phi3.5

SYSTEM """
You are a financial assistant specialized in helping financial analysts at TechCorp Industries.
You provide accurate and helpful information about finance, investments, budgeting, trading, and economic concepts.
"""

# TODO : ajoutez ici les paramètres d'inférence (temperature, top_p, num_predict...)
PARAMETER temperature 0.3
PARAMETER top_p 0.9
PARAMETER top_k 40
PARAMETER num_predict 1024
PARAMETER repeat_penalty 1.1
```

Phi3.5 étant un modèle très léger (-4B de paramètres) il s'intègre parfaitement avec nos contraintes matérielles.

```
vito@hia-ollama:~$ sudo systemctl status ollama.service
● ollama.service - Ollama Service
   Loaded: loaded (/etc/systemd/system/ollama.service; enabled; preset: enabled)
   Drop-In: /etc/systemd/system/ollama.service.d
            └─override.conf
   Active: active (running) since Tue 2026-06-30 15:51:26 CEST; 1h 11min ago
 Invocation: 66a6266c2bd84a39851ba75487d47a5c
    Main PID: 58179 (ollama)
      Tasks: 17 (limit: 77101)
     Memory: 24.2M (peak: 3.6G)
        CPU: 2h 32min 4.873s
    CGroup: /system.slice/ollama.service
            └─58179 /usr/local/bin/ollama serve
```

4. Accessibilité du serveur

Le serveur est disponible via l'API Ollama sur <http://localhost:11434/>

Il est également possible d'accéder au model directement dans la console en tapant la commande :

```
ollama run techcorp-finance:latest
```

```
vito@hia-ollama:~$ ollama run techcorp-finance:latest
>>> Send a message (/? for help)
```

5. Application Frontend

Le serveur frontend produit par l'équipe DEV est conteneurisé et servi par Nginx, voici l'extrait du Dockerfile réalisé par l'équipe INFRA :

```

FROM node:24-alpine AS builder

WORKDIR /app

COPY package.json package-lock.json ./

RUN npm ci

COPY . .
RUN npm run build

FROM nginx:stable-alpine

COPY --from=builder /app/dist /usr/share/nginx/html

EXPOSE 80

CMD ["nginx", "-g", "daemon off;"]

```

Le frontend est servi sur le port 3000.

```

vito@hia-ollama:~$ sudo docker ps
[sudo] password for vito:
CONTAINER ID   IMAGE                                COMMAND                  CREATED        STATUS
PORTS         NAMES
5dc2c2ef9659   vitoderiu/techcorp-ai-chat:1.2     "/docker-entrypoint..." 55 minutes ago Up 55 minute
s             0.0.0.0:3000->80/tcp, [::]:3000->80/tcp   upbeat_williamson
vito@hia-ollama:~$

```

6. Nom de domaine et Accès Cloudflare

L'application est disponible sur internet via l'adresse <https://ynovws.com/>. La VM se trouvant dans un réseau privé la résolution DNS s'effectue via tunnel Cloudflare ce qui permet de n'exposer aucun port du routeur sur internet.

Metrics

Active replicas ①

1

Routes ②

2

Status

Healthy

Uptime

3 hours

Replicas ③

+ Add a replica

Replica ID	Origin IP	Edge Locations	Version	Architecture	Uptime
		mrs06, mrs04, mrs04, mrs06	2026.6.1	linux_amd64	3 hours

Routes ④

View all →

ynovws.com ↗

Published application

ssh.ynovws.com ↗

Published application

home

7. Application rendu sur internet

L'application est disponible sur internet et communique correctement avec le serveur

The image displays two screenshots of the TechCorp AI web application interface, showing a chat conversation with the AI assistant.

Top Screenshot:

- Header:** TechCorp AI, Connecté
- Left Sidebar:**
 - + Nouvelle conversation (Ctrl+K)
 - Rechercher dans les discussions
 - Récentes: Hello
 - Mode sombre
 - Effacer tout l'historique
 - Techcorp-Finance:Latest (Serveur en ligne)
- Chat Area:**
 - Input: Hello !
 - TechCorp AI: Bonjour ! Je suis là pour vous assister avec tout lié à l'argent, les investissements et la finance :
 - List of services:
 - Investissement**:** Fournissez des conseils sur divers types d'investissements tels que le placement en actions, obligations ou immobilier. Analysez leur risque/récompense potentiel pour les investisseurs individuels.
 - Budgeting**:** Aidez à créer un plan de budget personnalisé qui peut aider une personne ou une entreprise à gérer plus efficacement leurs finances.
 - Trading Crypto-monnaies (CMC)**:** Offrez des conseils sur les meilleures pratiques pour le trading d'actifs numériques, y compris la sélection de portefeuilles et l'analyse technique/fundamentaliste.
 - Foncier & Immobilier locatif (FIM)**:** Fournissez des conseils sur les investissements immobiliers à travers le processus d'achat, la gestion de propriétés ou même l'investissement dans un : ↓ . communautaire foncier
 - Input: Demander à TechCorp AI...
 - Footer: Les réponses sont générées par IA et peuvent contenir des erreurs. Vérifiez les informations financières sensibles.

Bottom Screenshot:

- Header:** TechCorp AI, Connecté
- Left Sidebar:** (Same as top screenshot)
- Chat Area:**
 - Input: parle moi en plus sur le FIM
 - TechCorp AI: Le Foncier & Immobilier Locatif (FIM) est une stratégie d'investissement qui consiste à acquérir des propriétés pour les louer. Voici un aperçu détaillé :
 - List of services:
 - Acquisition de Propriété**:** Le premier pas dans le FIM implique l'achat ou la location-toi d'une propriété, généralement en utilisant une hypothèque bancaire. Les types courants incluent les maisons à appartements et les complexes immobiliers entiers.
 - Gestion de Propriété**:** Cela comprend des tâches telles que la recherche d'un locataire, l'examen du potentiel bailleur, le signalement légal (si nécessaire), établissement et négociation des contrats avec les locataires.
 - Maintenance & Améliorations**:** Les propriétaires doivent s'assurer que la propriété est bien entretenue pour attirer et conserver de bons locataires. Cela peut inclure le remplacement des ampoules, le ↓ arations mineures ou même certaines améliorations (comme une nouvelle cuisine).
 - Input: Demander à TechCorp AI...
 - Footer: Les réponses sont générées par IA et peuvent contenir des erreurs. Vérifiez les informations financières sensibles.